Università degli Studi di Catania

Dipartimento di Matematica e Informatica

Corso di Laurea Magistrale in Informatica LM-18

Rilevamento di POI senza Bounding Box Annotate

Pseudo-Label da DINOv3 (WSOL) e Distillazione in YOLOv8

Studio di Sample Efficiency e Capacity Retention sul Dataset Monumentale UNICT-VEDI

Studente:

Giovanni Piccinini

Matricola 1000097151

Corso:

Deep Learning - Core Models and Methods

Docenti:

Prof. Giovanni Maria Farinella

Prof. Francesco Ragusa

Anno Accademico 2025/2026

Sommario

L'annotazione manuale di riquadri di delimitazione (*bounding box*) per l'object detection richiede tempo e risorse considerevoli, in particolare nei domini specialistici come i beni culturali. In questo lavoro si esamina il paradigma della *Weakly-Supervised Object Localization* (WSOL) applicato al dataset egocentrico UNICT-VEDI POI, che raccoglie 57 classi di elementi monumentali nel Monastero dei Benedettini di Catania.

Sfruttando le feature di auto-segmentazione del modello DINOv3 ViT-S/16 con testa lineare (*linear probing*), è stata definita una procedura basata su Linear-CAM per ricavare pseudo-annotazioni spaziali a partire dalle sole etichette di classe dell'immagine. Le etichette così generate servono ad addestrare il rilevatore compatto YOLOv8n, senza impiegare coordinate cartesiane supervisionate nel processo di apprendimento.

Per quantificare il risparmio di annotazione, è stato impostato un confronto di *sample efficiency* rispetto a baseline supervisionate addestrate su quote progressive ($1\% \dots 100\%$) del ground truth con tre repliche stocastiche. Il modello distillato ottiene il 37.39% di mAP@50, prestazione equivalente all'1.43% di dati etichettati a mano e pari al 61.79% della capacità del rilevatore supervisionato al 100%. L'analisi per scala dimensionale evidenzia una ritenzione del 63.60% nel Tier Macro (26 classi di taglia intermedia non degeneri) e dell'84.14% nel Tier Full-Frame. L'esame dei fallimenti nel Tier Tiny (0.00% mAP@50) mostra inoltre che l'errore sistematico non deriva dalla risoluzione spaziale delle patch, ma dal bias di contesto e dall'*attribution leakage*: i massimi di attivazione del classificatore scivolano sulle strutture murarie contigue anziché sul piccolo reperto da localizzare.

Indice

Sommario **i**

1 Introduzione e Definizione del Problema **1**
1.1 Contesto Applicativo: Visione Egocentrica nei Beni Culturali 1
1.2 L'Asimmetria dei Costi di Annotazione 1
1.3 Domanda di Ricerca 1
1.4 Panoramica della Pipeline Proposta 2
1.5 Organizzazione del Documento 2

2 Il Dataset UNICT-VEDI POI e Sanitizzazione delle Annotazioni **3**
2.1 Struttura e Origine del Dataset UNICT-VEDI POI 3
2.1.1 Origine scientifica e contesto applicativo 3
2.1.2 Tassonomia delle classi e articolazione spaziale 3
2.1.3 Organizzazione tra Training e Test Set 3
2.2 Sanitizzazione delle Annotazioni del Dataset 4
2.2.1 Trattamento dei fotogrammi privi di bounding box: Convenzione Full-Frame 4
2.3 Analisi dell'Area Media per Classe e Definizione dei Tier Dimensionali . . . 5
2.3.1 Motivazione metodologica 5
2.3.2 Formulazione e distribuzione nei 4 tier 5
2.3.3 Caratteristiche dei singoli tier 5

3 DINOv3 e Architettura del Classificatore **6**
3.1 Vision Transformer e Paradigma DINO 6
3.1.1 Fondamenti del Vision Transformer 6
3.1.2 Pre-addestramento auto-supervisionato in DINOv3 6
3.2 Backbone ViT-S/16 e Testa Lineare 7
3.2.1 Configurazione del backbone 7
3.2.2 Linear Probing con backbone congelato 8
3.3 Discretizzazione in Patch e Risoluzione Spaziale 8
3.4 Metodi di Attribuzione per la Localizzazione Debole (WSOL) 8

4 Training e Prestazioni del Classificatore DINOv3 **10**
4.1 Setup Sperimentale e Metodologia di Addestramento 10
4.1.1 Preprocessing e Data Augmentation 10
4.1.2 Ottimizzazione e iperparametri 10
4.2 Risultati di Classificazione sul Test Set Ufficiale 11
4.2.1 Metriche globali 11
4.2.2 Prestazioni disaggregate per Tier dimensionale 11
4.2.3 Analisi del Tier Tiny 11
4.2.4 Analisi Topologica degli Errori 12

5 Generazione delle Pseudo-Label (WSOL) 13
5.1 Dalle Mappe di Attivazione ai Bounding Box . . . 13
5.1.1 Normalizzazione e sovracampionamento . . . 13
5.1.2 Binarizzazione differenziata . . . 13
5.1.3 Filtraggio morfologico ed estrazione del box . . . 14
5.2 Benchmark Comparativo sui Metodi CAM . . . 14
5.3 Risultati Sperimentali e Selezione . . . 14
5.3.1 Confronto quantitativo globale e per Tier . . . 14
5.3.2 Analisi qualitativa e selezione . . . 14

6 Distillazione della Conoscenza in YOLO 16
6.1 Costruzione del Dataset Pseudo-Etichettato . . . 16
6.1.1 Criteri di selezione e codifica . . . 16
6.1.2 Statistiche della distillazione . . . 16
6.2 Addestramento dello Studente (YOLOv8n) . . . 17
6.2.1 Scelta architetturale . . . 17
6.2.2 Partizionamento e iperparametri . . . 17
6.3 Convergenza Interna e Gap di Generalizzazione . . . 17

7 Baseline Supervisionate e Protocollo di Sample Efficiency 19
7.1 Obiettivo e Disegno Sperimentale . . . 19
7.1.1 Frazioni di campionamento e controllo della varianza . . . 19
7.2 Metriche di Valutazione e Condizioni di Fairness . . . 20

8 Risultati Sperimentali e Analisi Critica 21
8.1 Risultati Globali: Punto di Pareggio e Ritenzione di Capacità . . . 21
8.2 Analisi Disaggregata per Scala (Tier Dimensionale) . . . 22
8.3 Analisi del Tier Tiny: Bias Contestuale e Attribution Leakage . . . 22
8.4 Baseline Box a Tutta Immagine e Disaccoppiamento . . . 23
8.5 Gap di Generalizzazione dello Studente . . . 23

9 Limiti della Metodologia 24
9.1 Assunzione di Singola Istanza per Immagine . . . 24
9.2 Bias Contestuale e Disallineamento Discriminativo . . . 24
9.3 Rigidità della Soglia Costante . . . 24
9.4 Approssimazione Rettangolare di Maschere Irregolari . . . 24
9.5 Domain Shift Dinamico tra Training e Test . . . 24

10 Conclusioni e Sviluppi Futuri 26
10.1 Risposta alla Domanda di Ricerca . . . 26
10.2 Sviluppi Futuri . . . 26

Bibliografia 27

A Iperparametri Completi e Protocollo Sperimentale 29
A.1 Classificatore DINOv3 (Linear Probing) . . . 29
A.2 Pipeline di Estrazione Bounding Box (WSOL) . . . 29
A.3 Addestramento del Modello Studente (YOLOv8n Distillato) . . . 29
A.4 Protocollo Sperimentale di Sample Efficiency . . . 29

B Tassonomia Completa delle Classi e Aree Medie 34
B.1 Prospetto delle 57 Classi POI . . . 34

C Ambiente di Esecuzione, Note Tecniche e Riproducibilità **36**
C.1 Stack Software e Librerie di Riferimento 36
C.2 Risorse Hardware e Accelerazione di Calcolo 36
C.3 Protocollo di Riproducibilità e Controllo del Determinismo 36
C.4 Condizioni di Licenza e Conformità dei Dati 37

Elenco delle figure

3.1 Architettura di pre-addestramento auto-supervisionato DINOv3 [1]. La rete Student è ottimizzata su obiettivi congiunti ($\mathcal{L}_{\text{DINO}}$, $\mathcal{L}_{\text{iBOT}}$, $\mathcal{L}_{\text{Gram}}$, $\mathcal{L}_{\text{KoLeo}}$); la rete Teacher è aggiornata tramite EMA, guidando la distillazione a livello globale ([CLS]) e denso (patch). 7
3.2 Flusso computazionale del classificatore: il backbone ViT-S/16 congelato fornisce sia il token [CLS] per la predizione di classe (ramo superiore), sia i token di patch impiegati per l'attribuzione Linear-CAM (ramo inferiore). . 8

5.1 Pipeline di estrazione dei bounding box da mappe di salienza: normalizzazione e upsampling bicubico, binarizzazione differenziata, apertura morfologica e circoscrizione del contorno attorno al picco. 13
5.2 Analisi qualitativa di Linear-CAM a confronto con il ground truth: (a–c) successi su scale Macro e Full-Frame con elevata concordanza geometrica (IoU ≥ 0.79); (d–f) fallimenti tipici su elementi Tiny dovuti a dispersione contestuale e dislocamento del picco di salienza (Verde: Ground Truth, Rosso: predizione DINO, Giallo: picco di attivazione). 15

6.1 Flusso di distillazione del dataset: inferenza del Teacher DINOv3, filtraggio di confidenza, estrazione dei bounding box Linear-CAM, codifica YOLO e addestramento dello Student YOLOv8n. 16

7.1 Disegno sperimentale del benchmark di Sample Efficiency: partizionamento stratificato del budget di annotazione umana su 7 frazioni (con 3 repliche stocastiche e validazione interna), confrontato con lo studente distillato sul test set ufficiale non visto. 19

8.1 Ritenzione relativa di mAP@50 dello studente distillato (0% GT) rispetto all'oracolo 100% disaggregata per tier dimensionale. 22
8.2 Disallineamento discriminativo sui quattro soggetti del Tier Tiny: (a) Sant'Agata (area 5.1%), (b) Cupola (area 7.2%), (c) Santa Scolastica (area 4.5%) e (d) Bassorilievi Mancanti (area 3.1%). In tutti i casi le mappe di salienza isolano porzioni del reperto, ma il picco globale di attivazione (mirino giallo) si sposta sulla struttura architettonica contigua o sullo sfondo murario, generando uno pseudo-box errato (rosso) rispetto al Ground Truth (verde). 23

Elenco delle tabelle

2.1 Specifiche strutturali del dataset egocentrico UNICT-VEDI POI. 3
2.2 Distribuzione delle 57 classi di POI nei 9 macro-ambienti monumentali. . . 4
2.3 Segmentazione delle 57 classi del dataset UNICT-VEDI POI nei quattro tier dimensionali analitici (in Area Media e Range sono riportate le quote percentuali dell'inquadratura). 5

3.1 Parametri architetturali del backbone DINOv3 ViT-S/16. 7

4.1 Configurazione degli iperparametri per il training del classificatore DINOv3. 10
4.2 Prestazioni globali del classificatore DINOv3 sul Test Set ufficiale. 11
4.3 Prestazioni del classificatore disaggregate per fascia dimensionale (Tier). . . 11
4.4 Scomposizione topologica delle predizioni del classificatore sui 9 macro-ambienti. 12
4.5 Matrice di confusione aggregata 9×9 tra i macro-ambienti monumentali. . 12

5.1 Benchmark comparativo dei metodi WSOL su 57.000 immagini: prestazioni globali e disaggregate per scala. 14
5.2 Comportamento qualitativo e rischi strutturali dei metodi WSOL indagati. 15

6.1 Statistiche quantitative del processo di distillazione del dataset. 17
6.2 Iperparametri di addestramento di YOLOv8n sul dataset distillato. 17

8.1 Confronto prestazionale tra baseline supervisionate (7 frazioni GT con 3 seed stocastici) e YOLOv8n distillato (0% GT) sul Test Set ufficiale. 21
8.2 Prestazioni comparative di mAP@50 (%) e ritenzione disaggregate per tier. 22

A.1 Specifiche dettagliate del classificatore DINOv3 in regime di Linear Probing. 30
A.2 Parametri operativi della pipeline deterministica WSOL. 31
A.3 Iperparametri completi di addestramento per YOLOv8n distillato. 32
A.4 Parametri di controllo del benchmark comparativo di Sample Efficiency. . . 33

C.1 Ecosistema software e framework scientifici impiegati. 36

CAPITOLO 1

Introduzione e Definizione del Problema

1.1 Contesto Applicativo: Visione Egocentrica nei Beni Culturali

La *First-Person Vision* (FPV), o visione egocentrica, cattura flussi visivi tramite dispositivi indossabili (*wearable cameras* o visori) dal punto di vista prospettico del visitatore. Nei contesti museali o monumentali, individuare in tempo reale i punti di interesse (POI) osservati dall'utente (*attended objects*) è il passo preliminare per costruire sistemi interattivi di guida e fruizione culturale.

Come benchmark di riferimento viene adottato il dataset UNICT-VEDI POI [2], acquisito nel complesso del Monastero dei Benedettini di San Nicolò l'Arena a Catania. Il corpus raccoglie 57 classi di elementi storici e architettonici (dipinti, affreschi, portali e ambienti) ripresi durante percorsi di visita continui.

1.2 L'Asimmetria dei Costi di Annotazione

I modelli supervisionati di object detection richiedono grandi quantità di riquadri di delimitazione (*bounding box*) tracciati a mano. Nei beni culturali questo comporta un netto sbilanciamento nei costi di etichettatura:

- **Supervisione a livello di immagine (*image-level*)**: annotare la presenza del POI nella scena richiede circa $1-2$ secondi per fotogramma ed è spesso ricavabile da log di visita o sensori di prossimità.
- **Supervisione geometrica (*bounding box*)**: delimitare i contorni di opere asimmetriche o parzialmente occluse richiede $20-30$ secondi per fotogramma, diventando presto insostenibile su raccolte video di decine di migliaia di fotogrammi.

Questo divario di costi motiva l'interesse per la *Weakly-Supervised Object Localization* (WSOL) [3–5], che mira a ricavare la posizione 2D degli oggetti partendo dalle sole etichette di presenza nell'immagine.

1.3 Domanda di Ricerca

La letteratura su WSOL si concentra quasi sempre su metriche isolate di localizzazione (come mAP@50 o MaxBoxAcc). Sul piano pratico ed economico resta però aperta una domanda diretta:

> *«A quale frazione di dati annotati manualmente con bounding box equivale un sistema di localizzazione addestrato senza alcuna annotazione geometrica supervisionata?»*

Nel presente lavoro si misura la *sample efficiency* della supervisione debole, determinando a quale quota percentuale di ground truth manuale corrisponda il modello distillato e quanta frazione della capacità del rilevatore pienamente supervisionato (l'oracolo al 100%) venga effettivamente preservata.

1.4 Panoramica della Pipeline Proposta

Per rispondere alla domanda, la sperimentazione è stata organizzata in cinque fasi:

1. **Modello teacher (DINOv3)**: addestramento di una testa lineare su backbone Vision Transformer congelato (ViT-S/16) [1, 6, 7], mantenendo intatte le feature di auto-segmentazione spaziale.

2. **Attribuzione spaziale (WSOL)**: estrazione delle mappe di salienza con Linear-CAM e confronto comparativo con *DINO Self-Attention*, *Eigen-CAM* [8] e *Grad-CAM* [9].

3. **Generazione di pseudo-label**: trasformazione deterministica delle heatmap in riquadri in formato YOLO tramite sogliatura proporzionale, apertura morfologica ed estrazione del poligono sul picco di attivazione.

4. **Distillazione dello studente (YOLOv8n)**: addestramento del rilevatore leggero YOLOv8n (3.2M parametri) [10] sull'insieme di immagini etichettato automaticamente dal teacher.

5. **Valutazione di sample efficiency**: confronto dello studente distillato con 19 baseline supervisionate addestrate su 7 quote di ground truth ($1\% \ldots 100\%$) su 3 seed casuali, valutate sul test set ufficiale.

1.5 Organizzazione del Documento

Il documento è organizzato come segue: il Capitolo 2 descrive il dataset VEDI, la pulizia dei dati e la suddivisione in tier dimensionali; il Capitolo 3 presenta l'architettura DINOv3 e la derivazione di Linear-CAM; il Capitolo 4 riporta i risultati di classificazione e la distribuzione degli errori nelle sale; il Capitolo 5 confronta i 4 metodi CAM; il Capitolo 6 illustra la distillazione in YOLOv8n; il Capitolo 7 descrive il protocollo di sample efficiency; il Capitolo 8 analizza il punto di pareggio, la ritenzione di capacità e il bias contestuale sulle classi Tiny; i Capitoli 9 e 10 discutono i limiti riscontrati, le conclusioni e le possibili estensioni. Le Appendici A–C contengono i parametri completi, la tassonomia delle classi e le note di riproducibilità.

CAPITOLO 2

Il Dataset UNICT-VEDI POI e Sanitizzazione delle Annotazioni

2.1 Struttura e Origine del Dataset UNICT-VEDI POI

2.1.1 Origine scientifica e contesto applicativo

Il benchmark utilizzato è il dataset UNICT-VEDI POI [2], curato dall'IPLab dell'Università di Catania all'interno del progetto VEDI. I dati appartengono all'ambito della *First-Person Vision* (FPV) nei beni culturali: i video sono stati acquisiti tramite videocamere indossate da visitatori all'interno del Monastero dei Benedettini di San Nicolò l'Arena a Catania.

Il compito applicativo consiste nell'individuare automaticamente i punti di interesse (POI) osservati dall'utente (*attended objects*). Il corpus comprende affreschi, tele, sculture, portali ed elementi architettonici, con le caratteristiche sintetiche riportate nella Tabella 2.1.

Proprietà del Dataset	**Valore / Dettaglio Operativo**
Sito monumentale	Monastero dei Benedettini di San Nicolò l'Arena (Catania)
Tipologia dati	Fotogrammi da video egocentrici (1216×684 pixel)
Numero di classi POI	57 classi distribuite su 9 macro-ambienti storici
Volume Training Set	67.050 immagini (organizzate per cartella di classe)
Volume Test Set	5.462 immagini (distribuite su 7 sessioni continue di visita)
Formato annotazioni	Coordinate bounding box normalizzate (x_c, y_c, w, h)

Tabella 2.1: Specifiche strutturali del dataset egocentrico UNICT-VEDI POI.

2.1.2 Tassonomia delle classi e articolazione spaziale

I 57 POI sono distribuiti nei 9 macro-ambienti del monastero (Tabella 2.2). L'elenco integrale classe per classe con le aree medie è riportato in Appendice B.

2.1.3 Organizzazione tra Training e Test Set

L'organizzazione tra addestramento e test presenta una differenza strutturale importante:

- **Training set (67.050 immagini)**: le immagini sono raggruppate in 57 cartelle, una per ciascuna classe di POI.
- **Test set (5.462 immagini)**: i fotogrammi provengono da 7 sessioni continue di visita a passo d'uomo (`Test1`–`Test7`). Di questi, 3.673 fotogrammi presentano annotazioni di ground truth con coordinate geometriche; i rimanenti corrispondono a momenti di passaggio tra ambienti privi di soggetti catalogati.

Macro-Ambiente Storico	POI (N)	Esempi Rappresentativi
1. Ingresso Monumentale	1	Ingresso
2. Scalone Monumentale	2	Rampa S. Nicola, Rampa S. Benedetto
3. Chiostro e Corridoi	11	Chiostro Levante, Affresco, Traccia Portone, Corridoi
4. Cantoria e Chiesa	3	Quadro, Pavimento Orig. Altare, Balcone Chiesa
5. Antirefettorio e Museo	10	Portali, Cupola, S. Agata, S. Scolastica, Busto Vaccarini
6. Coro di Notte e Aula	9	Quadro Mazzarino, Bassorilievi Mancanti, Lavamani, Poltrone
7. Refettorio Piccolo	7	Edicola, Pavimenti A/B, Passavivande, Scala, Sala Metereologica
8. Cucine e Sotterranei	11	Doccione, Cucine, Ghiacciaia, Cisterna, Busto Tacchini
9. Giardino dei Novizi	3	Nicchia e Pavimento, Tracce Palestra, Pergolato
Totale Complesso	**57**	Tassonomia completa dettagliata in Appendice B

Tabella 2.2: Distribuzione delle 57 classi di POI nei 9 macro-ambienti monumentali.

2.2 Sanitizzazione delle Annotazioni del Dataset

L'analisi preliminare dei file di etichetta in formato YOLO ($[x_c, y_c, w, h] \in [0,1]^4$) ha evidenziato anomalie corrette tramite tre passaggi di pulizia:

1. **Normalizzazione delle coordinate**: i riquadri salvati con coordinate assolute in pixel (valori maggiori di 1.5) sono stati ricondotti all'intervallo $[0, 1]$ dividendo per le dimensioni d'origine del fotogramma ($W = 1216, H = 684$).

2. **Troncamento ai bordi (*clamping*)**: le coordinate esterne all'immagine sono state tagliate sull'intervallo $[0.0, 1.0]$, ponendo $x_{\min}^{\text{clamp}} = \max(0.0, \min(1.0, x_{\min}))$ e analogamente per gli altri tre vertici.

3. **Rimozione dei riquadri degeneri**: sono state rimosse le annotazioni con larghezza o altezza inferiori a $\epsilon = 10^{-3}$, per evitare divergenze numeriche nel calcolo dell'Intersection over Union.

2.2.1 Trattamento dei fotogrammi privi di bounding box: Convenzione Full-Frame

Nel set di addestramento, 3.106 fotogrammi (circa il 4.6% del totale) sono privi di file di etichetta. Seguendo la documentazione ufficiale del dataset rilasciata dagli autori:

> *«Some folders have not the two *.csv files, in this case for each related RGB frame you have to consider a bounding box which contains the whole frame.»*

è stata assegnata a queste immagini la classe associata alla cartella e un riquadro esteso all'intero fotogramma ($[x_c = 0.5, y_c = 0.5, w = 1.0, h = 1.0]$). Questa scelta modella le situazioni in cui l'ambiente o la parete monumentale occupa completamente la vista dell'utente.

2.3 Analisi dell'Area Media per Classe e Definizione dei Tier Dimensionali

2.3.1 Motivazione metodologica

Le dimensioni apparenti dei soggetti nel dataset variano da piccoli dettagli scultorei a lunghi corridoi. Valutare i modelli solo tramite la metrica mAP aggregata nasconderebbe differenze marcate nel comportamento del Vision Transformer a scale spaziali diverse.

Nota metodologica sui Tier. La ripartizione in fasce dimensionali (tier) non appartiene alla specifica originaria del dataset VEDI: è stata introdotta in questo studio per analizzare il rendimento dei metodi in funzione dell'ingombro relativo dell'oggetto.

2.3.2 Formulazione e distribuzione nei 4 tier

I tier sono calcolati a livello di classe mediante l'area media normalizzata $\bar{A}_c$ occupata dal riquadro di ground truth su tutte le occorrenze:

$$\bar{A}_c = \frac{1}{N_c} \sum_{i=1}^{N_c} (w_{c,i} \cdot h_{c,i}) \in [0.0, 1.0] \tag{2.1}$$

Le 57 classi sono state quindi ripartite in quattro fasce (Tabella 2.3).

Tier	Soglia ($\bar{A}_c$)	Classi	Quota	Area Media	Range	Esempi
Tiny	≤ 0.10	**4**	7.0%	**4.97%**	3.1% – 7.2%	Bassorilievi, S. Agata
Small	$0.10 - 0.30$	**3**	5.3%	**26.27%**	21.9% – 29.7%	Quadro Mazzarino, Lavamani
Macro	$0.30 - 0.80$	**27**	47.4%	**61.19%**	31.5% – 78.6%	Portali, affreschi, altari
Full-Frame	≥ 0.80	**23**	40.3%	**93.09%**	81.3% – 99.8%	Corridoi, scalinate, sale
Totale	—	**57**	100%	**70.75%**	3.1% – 99.8%	—

Tabella 2.3: Segmentazione delle 57 classi del dataset UNICT-VEDI POI nei quattro tier dimensionali analitici (in Area Media e Range sono riportate le quote percentuali dell'inquadratura).

2.3.3 Caratteristiche dei singoli tier

1. **Tier Tiny (4 classi, area $\bar{A}_c \leq 0.10$)**: elementi circoscritti (Bassorilievi, S. Agata, S. Scolastica, Cupola). Costituiscono il caso più critico per la localizzazione debole, sia per la discretizzazione spaziale a patch, sia per la predominanza visiva della muratura circostante.

2. **Tier Small (3 classi, $0.10 < \bar{A}_c < 0.30$)**: soggetti delimitati (Quadro Mazzarino, Lavamani, Busto Tacchini). Con lo sfondo che copre tra il 70% e il 90% della scena, le mappe di attivazione tendono a disperdersi sui muri d'appoggio.

3. **Tier Macro (27 classi, $0.30 \leq \bar{A}_c < 0.80$)**: il gruppo più numeroso (47.4%). Raccoglie portali, affreschi e scalinate in cui il soggetto riempie buona parte dell'inquadratura ma conserva contorni netti rispetto all'ambiente.

4. **Tier Full-Frame (23 classi, $\bar{A}_c \geq 0.80$)**: corridoi e sale ampie con copertura media del 93.1%. In questa fascia il compito geometrico coincide nei fatti con la classificazione dell'ambiente, dato che il riquadro corretto coincide quasi per intero con l'immagine.

CAPITOLO 3

DINOv3 e Architettura del Classificatore

3.1 Vision Transformer e Paradigma DINO

3.1.1 Fondamenti del Vision Transformer

L'architettura *Vision Transformer* (ViT) [11] adatta il meccanismo di auto-attenzione (*self-attention*) [12] alla visione artificiale. Un'immagine d'ingresso $I \in \mathbb{R}^{H\times W\times C}$ viene suddivisa in $N = (H \cdot W)/P^2$ patch bidimensionali disgiunte di lato P. Ciascuna patch viene proiettata linearmente in uno spazio latente di dimensione D. Alla sequenza risultante è anteposto un token apprendibile ($\mathbf{z}_{\text{CLS}} \in \mathbb{R}^D$), deputato a raccogliere la semantica globale, ed è sommato un vettore di posizione $\mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1)\times D}$:

$$\mathbf{z}_0 = \left[\mathbf{z}_{\text{CLS}};\, \mathbf{x}_p^1\mathbf{E};\, \ldots;\, \mathbf{x}_p^N\mathbf{E}\right] + \mathbf{E}_{\text{pos}} \tag{3.1}$$

La sequenza attraversa L blocchi di *Transformer Encoder*, composti da strati alternati di *Multi-Head Self-Attention* (MHSA) e *Multi-Layer Perceptron* (MLP), preceduti da normalizzazione di strato (*LayerNorm*):

$$\mathbf{z}'_\ell = \text{MHSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}, \quad \ell = 1, \ldots, L \tag{3.2}$$

$$\mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell \tag{3.3}$$

In ciascuna delle h teste, l'attenzione opera con dimensione $d_k = D/h$ mediante prodotto scalare scalato:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V} \tag{3.4}$$

Questo meccanismo offre un campo recettivo globale fin dal primo strato, correlando elementi visivi anche a grande distanza nell'immagine.

3.1.2 Pre-addestramento auto-supervisionato in DINOv3

Privo dell'inductive bias convoluzionale, ViT richiede ampi volumi di dati per apprendere rappresentazioni visive robuste. I modelli DINO [1, 6, 7] superano questo vincolo mediante auto-supervisione su larga scala: in DINOv3 l'addestramento impiega il corpus LVD-1689M (circa 1.7 miliardi di immagini).

Il framework si basa su una distillazione tra due reti omologhe (Figura 3.1): una rete **Student** con parametri θ_s, ottimizzata via gradiente, e una rete **Teacher** con parametri θ_t, aggiornata per media mobile esponenziale (EMA):

$$\theta_t \leftarrow \lambda\theta_t + (1-\lambda)\theta_s, \quad \lambda \in [0.99, 1.0] \tag{3.5}$$

DINOv3 combina tre funzioni di costo principali e un termine di regolarizzazione:

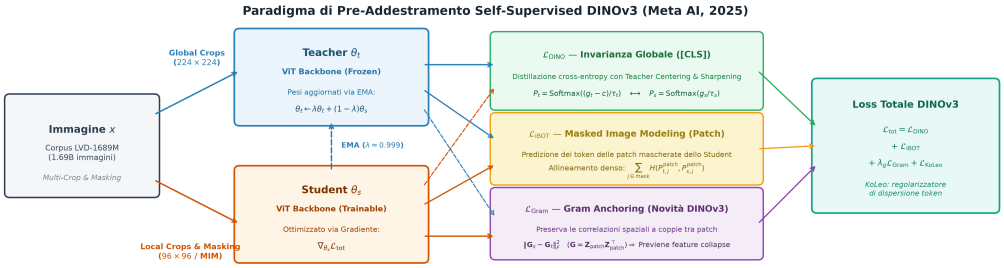

Figura 3.1: Architettura di pre-addestramento auto-supervisionato DINOv3 [1]. La rete Student è ottimizzata su obiettivi congiunti ($\mathcal{L}_{\text{DINO}}$, $\mathcal{L}_{\text{iBOT}}$, $\mathcal{L}_{\text{Gram}}$, $\mathcal{L}_{\text{KoLeo}}$); la rete Teacher è aggiornata tramite EMA, guidando la distillazione a livello globale ([CLS]) e denso (patch).

1. **Loss DINO** ($\mathcal{L}_{\text{DINO}}$): cross-entropy sui token [CLS] tra ritagli globali e locali. L'uscita del Teacher è stabilizzata tramite *centering* (sottrazione della media empirica dei logit) e *sharpening* (temperatura ridotta sul Softmax), inducendo invarianza alle trasformazioni geometriche.

2. **Loss iBOT** ($\mathcal{L}_{\text{iBOT}}$): masked image modeling a livello di patch token; lo Student predice le patch mascherate allineandosi alle rappresentazioni dense non mascherate del Teacher.

3. **Gram Anchoring** ($\mathcal{L}_{\text{Gram}}$): vincolo caratterizzante di DINOv3 che allinea le matrici di Gram (correlazioni a coppie tra patch) tra Student e Teacher, prevenendo il collasso delle feature dense durante l'ottimizzazione prolungata su scala miliardaria.

4. **Regolarizzatore KoLeo** ($\mathcal{L}_{\text{KoLeo}}$): massimizza l'entropia differenziale, distribuendo uniformemente i vettori latenti nello spazio unitario.

Questo schema integrato consente ai token dell'ultimo strato di catturare confini semantici e separare naturalmente l'oggetto in primo piano dallo sfondo, costituendo la premessa per la localizzazione debolmente supervisionata tramite mappe di attivazione.

3.2 Backbone ViT-S/16 e Testa Lineare

3.2.1 Configurazione del backbone

Nel presente lavoro viene impiegato il checkpoint ViT-S/16 pre-addestrato. I parametri architetturali sono riassunti nella Tabella 3.1.

Iperparametro	Valore	Descrizione Operativa
Dimensione latente (D)	384	Dimensione del vettore di embedding di ciascun token
Numero di strati (L)	12	Blocchi sequenziali di Transformer Encoder
Teste di attenzione (h)	6	Numero di teste nel modulo Multi-Head Self-Attention
Dimensione per testa (d_k)	64	Spazio di proiezione di ciascuna testa (384/6)
Dimensione patch (P)	16	Risoluzione spaziale di ciascuna patch (16×16 px)
Numero di parametri	≈ 22 M	Complessità parametrica complessiva del backbone

Tabella 3.1: Parametri architetturali del backbone DINOv3 ViT-S/16.

3.2.2 Linear Probing con backbone congelato

Per preservare lo spazio latente pre-addestrato ed evitare il *catastrophic forgetting*, il backbone è mantenuto a pesi congelati ($\nabla_{\theta_{\text{backbone}}} \mathcal{L} = 0$). Sul token globale $\mathbf{z}_{\text{CLS}}^{(L)} \in \mathbb{R}^{384}$ dell'ultimo strato è innestata una testa di classificazione lineare preceduta da Dropout ($p = 0.3$):

$$\hat{\mathbf{y}} = \mathbf{W} \cdot \text{Dropout}(\mathbf{z}_{\text{CLS}}^{(L)}) + \mathbf{b} \tag{3.6}$$

dove $\mathbf{W} \in \mathbb{R}^{57 \times 384}$ mappa i descrittori latenti sulle 57 classi del dataset e $\mathbf{b} \in \mathbb{R}^{57}$ è il vettore di bias.

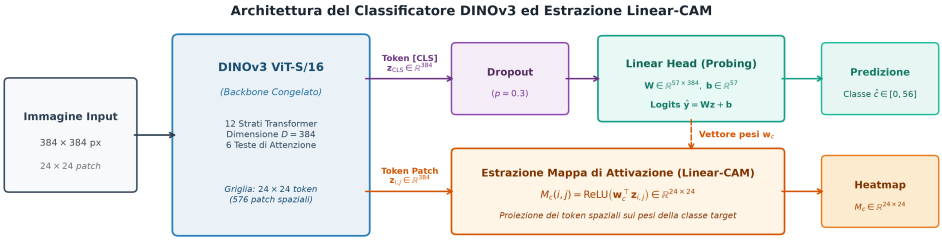

Figura 3.2: Flusso computazionale del classificatore: il backbone ViT-S/16 congelato fornisce sia il token [CLS] per la predizione di classe (ramo superiore), sia i token di patch impiegati per l'attribuzione Linear-CAM (ramo inferiore).

La linearità della testa fa sì che ciascuna riga $\mathbf{w}_c \in \mathbb{R}^{384}$ della matrice $\mathbf{W}$ corrisponda alla direzione prototipo per la classe c. Questa proprietà consente di valutare direttamente l'attivazione locale proiettando $\mathbf{w}_c$ sui singoli token di patch.

3.3 Discretizzazione in Patch e Risoluzione Spaziale

A risoluzione d'ingresso $H = W = 384$ pixel e lato patch $P = 16$, l'immagine viene suddivisa in una griglia regolare 24×24, per un totale di $N = 576$ token spaziali oltre al token [CLS]. Ogni cella (i, j) corrisponde a un'area di 16×16 pixel. Nei soggetti a scala ridotta (Tier Tiny, area relativa $3\% - 7\%$), il target copre appena $17 - 40$ celle; in tale intervallo, l'interpolazione continua e la sogliatura operano in prossimità del limite di risoluzione della griglia, aumentando la sensibilità a dispersioni di salienza sullo sfondo.

3.4 Metodi di Attribuzione per la Localizzazione Debole (WSOL)

La combinazione tra i token spaziali di DINOv3 e la testa lineare permette di calcolare quattro mappe di salienza continua $M_c(i, j) \in \mathbb{R}^{24 \times 24}$ per la classe predetta c:

1. **Linear-CAM (pesi di classe)** [13]:

$$M_{\text{Linear}}(i, j) = \text{ReLU}\left(\mathbf{w}_c^\top \mathbf{z}_{i,j}\right) \tag{3.7}$$

   dove $\mathbf{w}_c$ è il vettore dei pesi della classe c e $\mathbf{z}_{i,j}$ è l'embedding del token in (i, j).

2. **DINO Self-Attention**:

$$M_{\text{Attn}}(i, j) = \frac{1}{h} \sum_{k=1}^{h} \mathbf{A}_k^{(L)}[\text{CLS}, (i, j)] \tag{3.8}$$

ovvero l'attenzione del token [CLS] verso i token di patch all'ultimo strato.

3. **Eigen-CAM (decomposizione spettrale)** [8]:

$$M_{\text{Eigen}}(i,j) = \mathbf{V}_1^\top \mathbf{z}_{i,j} \tag{3.9}$$

proiettando le feature spaziali sul primo autovettore principale $\mathbf{V}_1$ ricavato via SVD.

4. **Grad-CAM (gradiente sui tensori intermedi)** [9]:

$$M_{\text{Grad}}(i,j) = \text{ReLU}\left(\sum_{d=1}^{D} \alpha_d^c \cdot z_{i,j,d}\right), \quad \alpha_d^c = \frac{1}{N}\sum_{i,j} \frac{\partial \hat{y}_c}{\partial z_{i,j,d}} \tag{3.10}$$

Il confronto quantitativo tra queste formulazioni è presentato nel Capitolo 5.

CAPITOLO 4

Training e Prestazioni del Classificatore DINOv3

4.1 Setup Sperimentale e Metodologia di Addestramento

4.1.1 Preprocessing e Data Augmentation

Il classificatore usa il backbone ViT-S/16 congelato con testa lineare a 57 classi descritto nella Sezione 3.2. Ogni fotogramma RGB viene ridimensionato a 384×384 pixel e normalizzato con i valori standard di ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$).

Per gestire le variazioni di illuminazione e di prospettiva tipiche delle riprese egocentriche indoor (zone in ombra, luce naturale variabile e rotazioni del capo), durante l'addestramento vengono applicate due forme di data augmentation stocastica:

- **Random Horizontal Flip**: riflessione orizzontale casuale con probabilità $p = 0.5$;
- **Color Jitter**: alterazione casuale di luminosità, contrasto e saturazione nell'intervallo $[0.7, 1.3]$ ($p = 0.5$ ciascuna) e lieve variazione della tonalità ($p = 0.3$).

In validazione e test ogni trasformazione casuale è disattivata.

4.1.2 Ottimizzazione e iperparametri

L'addestramento minimizza la consueta Cross-Entropy multiclasse:

$$\mathcal{L}_{\text{CE}}(\mathbf{y}, \hat{\mathbf{y}}) = -\sum_{c=1}^{57} y_c \log \left(\frac{\exp(\hat{y}_c)}{\sum_{j=1}^{57} \exp(\hat{y}_j)} \right) \tag{4.1}$$

Gli iperparametri impostati per l'ottimizzazione sono riassunti nella Tabella 4.1.

Parametro	Valore	Descrizione / Motivazione Operativa
Ottimizzatore	AdamW	$\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$
Learning Rate (η_0)	1×10^{-4}	Tasso di apprendimento sulla testa lineare
Weight Decay	1×10^{-4}	Regolarizzazione L_2 sui pesi della testa
Dimensione Batch	16	Compromesso stabilità gradiente e memoria VRAM
Numero di epoche	20	Criterio di arresto globale
LR Scheduler	Cosine + Warmup	Warmup lineare iniziale seguito da decadimento cosinusoidale
Dropout rate	0.3	Regolarizzazione applicata prima della proiezione
Miglior modello	Epoca 13	Checkpoint alla massima accuratezza di validazione (98.31%)

Tabella 4.1: Configurazione degli iperparametri per il training del classificatore DINOv3.

4.2 Risultati di Classificazione sul Test Set Ufficiale

4.2.1 Metriche globali

La valutazione è condotta sul test set ufficiale (5.462 immagini distribuite su 7 sessioni video continue), considerando i 3.673 fotogrammi provvisti di annotazioni di POI. Delle 57 classi del dataset, 56 compaiono nel test set (la classe `3.8_StanzaAbate` non presenta registrazioni nelle 7 sessioni). I risultati globali sono riportati nella Tabella 4.2.

Metrica Globale	Valore	Note Metodologiche
Top-1 Accuracy	**70.24%**	Frazione globale di predizioni corrette su 3.673 campioni
Top-5 Accuracy	**84.32%**	Classe reale inclusa nei primi 5 logit predetti
Macro Recall	**72.10%**	Media aritmetica del recall calcolata sulle 56 classi
Macro Precision	**73.54%**	Media aritmetica della precisione sulle classi valutate
Macro F1-Score	**70.00%**	Media non pesata della media armonica precision-recall
Weighted F1-Score	**70.23%**	Punteggio F1 ponderato sul supporto campionario di classe

Tabella 4.2: Prestazioni globali del classificatore DINOv3 sul Test Set ufficiale.

I valori di 70.24% di Top-1 Accuracy e 84.32% di Top-5 Accuracy su 56 classi attive indicano una buona capacità di discriminazione delle feature DINOv3 in riprese egocentriche non controllate.

4.2.2 Prestazioni disaggregate per Tier dimensionale

La Tabella 4.3 scompone le metriche lungo i 4 tier dimensionali del dataset.

Tier	Classi	Campioni	Acc. Mac.	Acc. Pes.	Prec. Mac.	F1 Mac.
Tiny (≤ 0.10)	4/4	98	**94.38%**	**90.82%**	79.48%	**83.86%**
Small ($0.11 - 0.30$)	3/3	104	**84.71%**	**85.58%**	78.10%	**80.66%**
Macro ($0.30 - 0.79$)	26/27	1.490	**66.10%**	**60.20%**	78.44%	**69.02%**
Full-Frame (≥ 0.80)	23/23	1.981	**73.38%**	**75.97%**	66.37%	**67.31%**
Complessivo	56/57	3.673	**72.10%**	**70.24%**	73.54%	**70.00%**

Tabella 4.3: Prestazioni del classificatore disaggregate per fascia dimensionale (Tier).

4.2.3 Analisi del Tier Tiny

L'apparente paradosso delle prestazioni massime conseguite sul Tier Tiny (94.38% di accuratezza macro e 90.82% pesata) deriva da due fattori:

1. **Supporto campionario ridotto**: il gruppo comprende 4 classi e appena 98 campioni nel test set (2.7% delle annotazioni complessive, a fronte dei 1.490 di Macro e 1.981 di Full-Frame). La ridotta variabilità dei punti di vista favorisce punteggi percentuali elevati.

2. **Ancoraggio al contesto**: il classificatore categorizza l'immagine riconoscendo non tanto il minuto manufatto in sé, quanto l'ambiente monumentale che lo contiene (volte, stucchi, pareti caratteristiche). Sebbene sufficiente per la classificazione d'immagine, questo ancoraggio contestuale disperde le attivazioni nella successiva localizzazione WSOL, compromettendo la generazione del bounding box.

4.2.4 Analisi Topologica degli Errori

La matrice di confusione completa a 57×57 classi è riportata nell'Appendice B. Per interpretare la struttura degli errori, le predizioni sono scomposte sui 9 macro-ambienti del complesso (Tabella 4.4).

Macro-Ambiente	Campioni	Top-1	Err. Intra	Err. Inter	Acc. Area
Area 1 — Ingresso	53	92.5%	—	7.5%	**92.5%**
Area 2 — Scalone	189	74.1%	23.3%	2.6%	**97.4%**
Area 3 — Chiostro/Corr.	1.461	53.8%	34.5%	11.7%	**88.3%**
Area 4 — Cantoria/Chiesa	384	89.8%	—	10.2%	**89.8%**
Area 5 — Antirefettorio	324	76.2%	18.5%	5.2%	**94.8%**
Area 6 — Coro di Notte	294	76.9%	19.4%	3.7%	**96.3%**
Area 7 — Ref. Piccolo	393	79.1%	18.6%	2.3%	**97.7%**
Area 8 — Cucine/Sott.	449	83.7%	14.9%	1.3%	**98.7%**
Area 9 — Giardino	126	79.4%	20.6%	**0.0%**	**100.0%**
Totale Globale	**3.673**	**70.24%**	**22.62%**	**7.13%**	**92.87%**

Tabella 4.4: Scomposizione topologica delle predizioni del classificatore sui 9 macro-ambienti.

Sui 3.673 fotogrammi di test si distinguono tre esiti:

- 70.24%: predizione esatta dell'opera specifica;
- 22.62%: errore intra-ambiente (il modello scambia due POI appartenenti alla medesima sala);
- 7.13%: errore inter-ambiente (scambio tra macro-ambienti differenti).

Il modello individua il macro-ambiente corretto nel 92.87% dei casi (70.24% + 22.62%). Sul totale degli errori commessi (29.76%), il 76.0% (22.62/29.76) è costituito da ambiguità locali tra soggetti contigui, mentre solo il 24.0% (7.13/29.76) rappresenta una confusione tra ambienti distinti.

Aggregando le predizioni nella matrice di confusione 9×9 (Tabella 4.5), la diagonale risulta nettamente dominante.

Area Reale	A1	A2	A3	A4	A5	A6	A7	A8	A9	Recall
1. Ingresso	**49**	0	1	1	0	0	0	0	2	**92.5%**
2. Scalone	1	**184**	4	0	0	0	0	0	0	**97.4%**
3. Chiostro/Corr.	62	44	**1290**	5	14	9	12	13	12	**88.3%**
4. Cantoria/Chiesa	0	1	7	**345**	0	31	0	0	0	**89.8%**
5. Antirefettorio	0	3	10	1	**307**	3	0	0	0	**94.8%**
6. Coro di Notte	0	0	5	2	2	**283**	1	1	0	**96.3%**
7. Ref. Piccolo	0	0	4	0	4	1	**384**	0	0	**97.7%**
8. Cucine/Sott.	0	0	1	1	0	0	4	**443**	0	**98.7%**
9. Giardino	0	0	0	0	0	0	0	0	**126**	**100.0%**

Tabella 4.5: Matrice di confusione aggregata 9×9 tra i macro-ambienti monumentali.

I rari scambi inter-ambiente riflettono la contiguità architettonica: l'Area 3 (Chiostro e Corridoi) scambia campioni principalmente con l'Area 1 (62 frame) e l'Area 2 (44 frame), che sono i varchi di passaggio; l'Area 4 (Cantoria) scambia 31 frame con l'Area 6 (Coro di Notte), poiché entrambe condividono lo scorcio prospettico sulla navata della chiesa.

CAPITOLO 5

Generazione delle Pseudo-Label (WSOL)

5.1 Dalle Mappe di Attivazione ai Bounding Box

Nella *Weakly-Supervised Object Localization* (WSOL), l'obiettivo è ricavare le coordinate geometriche degli oggetti disponendo soltanto delle etichette a livello di immagine. Le feature estratte da DINOv3 consentono di costruire mappe di salienza continua $M \in \mathbb{R}^{H \times W}$ tramite quattro formulazioni alternative (Linear-CAM, DINO Attn, Eigen-CAM, Grad-CAM), introdotte nella Sezione 3.4.

Per passare dalla mappa di calore alle coordinate del riquadro $[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$, è stata implementata la sequenza mostrata nella Figura 5.1.

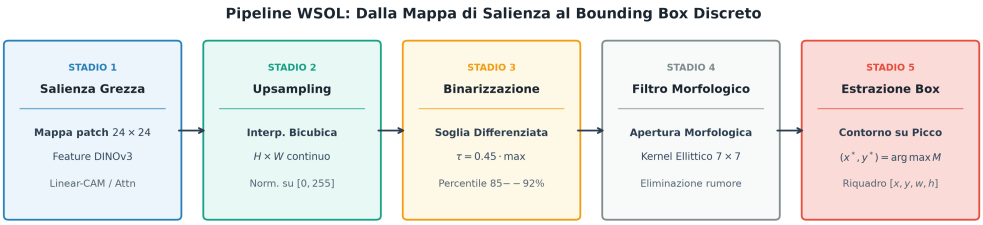

Figura 5.1: Pipeline di estrazione dei bounding box da mappe di salienza: normalizzazione e upsampling bicubico, binarizzazione differenziata, apertura morfologica e circoscrizione del contorno attorno al picco.

5.1.1 Normalizzazione e sovracampionamento

La mappa estratta sui token di patch $M(i,j) \in \mathbb{R}^{24 \times 24}$ viene normalizzata sull'intervallo $[0.0, 1.0]$:

$$\hat{M}(i,j) = \frac{M(i,j) - \min(M)}{\max(M) - \min(M) + \epsilon} \tag{5.1}$$

La matrice risultante viene quindi riscalata alla risoluzione originale dell'immagine ($W \times H$) tramite interpolazione bicubica, generando una mappa di intensità $\mathcal{H}(x,y) \in [0, 255]$ a 8 bit.

5.1.2 Binarizzazione differenziata

La conversione di $\mathcal{H}(x,y)$ nella maschera binaria $B(x,y) \in \{0, 255\}$ richiede una soglia commisurata al tipo di attivazione prodotta da ciascun metodo:

- **Metodi a risposta diffusa (`Linear-CAM`, `Eigen-CAM`)**: le risposte coprono l'oggetto in modo omogeneo; viene applicata una soglia proporzionale al valore massimo:

$$\tau_{\text{rel}} = 0.45 \cdot \max_{x,y} \mathcal{H}(x,y) \tag{5.2}$$

- **Metodi a risposta focalizzata o sparsa (`DINO Attn`, `Grad-CAM`)**: le attivazioni mostrano gradienti ripidi o picchi concentrati su pochi pixel. Una soglia proporzionale fissa porterebbe alla scomparsa della regione; viene perciò impiegata una soglia a percentile:

$$\tau_{\text{perc}} = \text{Percentile}_{85-92\%}(\mathcal{H}) \tag{5.3}$$

  imponendo una superficie minima attiva ($A_{\min} \geq 0.05 \cdot H \cdot W$).

5.1.3 Filtraggio morfologico ed estrazione del box

Sulla maschera binaria viene applicata un'apertura morfologica con elemento strutturante ellittico 7×7:

$$B_{\text{clean}} = (B \ominus K) \oplus K \tag{5.4}$$

per eliminare il rumore isolato e ricongiungere componenti vicine. Tra i contorni $\mathcal{C} = \{C_1, \ldots, C_k\}$ individuati su B_{clean}, viene selezionato il poligono C^* che racchiude il picco globale di salienza $(x^*, y^*) = \arg\max_{(x,y)} \mathcal{H}(x, y)$. Se nessun contorno contiene direttamente il picco, si sceglie il contorno con la maggiore intensità integrata. Il rettangolo minimo contenente C^* fornisce il bounding box finale.

5.2 Benchmark Comparativo sui Metodi CAM

Per scegliere il metodo di salienza più affidabile per la successiva distillazione, è stato svolto un confronto su 57.000 immagini di training (1.000 fotogrammi per classe). I riquadri generati sono stati confrontati con il ground truth calcolando mAP@50 (soglia IoU ≥ 0.50) e mAP@50:95.

5.3 Risultati Sperimentali e Selezione

5.3.1 Confronto quantitativo globale e per Tier

La Tabella 5.1 riporta i risultati numerici dei quattro metodi sulle 57.000 immagini, sia complessivamente sia suddivisi per tier dimensionale.

	Metriche Globali				mAP@50 per Tier (%)			
Metodo CAM	**mAP@50**	**mAP@50:95**	**Recall**	**IoU**	**Full-Fr.**	**Macro**	**Small**	**Tiny**
Linear-CAM	**64.65%**	**41.56%**	**69.10%**	**0.548**	**74.79%**	**68.04%**	**18.32%**	**0.00%**
DINO Attn	26.02%	16.11%	32.40%	0.312	32.15%	28.40%	11.20%	0.00%
Grad-CAM	15.70%	9.82%	21.50%	0.245	19.40%	17.10%	6.40%	0.00%
Eigen-CAM	12.94%	8.15%	17.80%	0.218	16.80%	13.50%	5.10%	0.00%

Tabella 5.1: Benchmark comparativo dei metodi WSOL su 57.000 immagini: prestazioni globali e disaggregate per scala.

Linear-CAM ottiene il punteggio più alto su tutte le metriche generali, superando di 38.63 punti la Self-Attention e di oltre 48 punti Grad-CAM ed Eigen-CAM. Nei tier Full-Frame e Macro raggiunge rispettivamente il 74.79% e il 68.04% di mAP@50, mentre si azzera sul Tier Tiny (0.00%) per tutte le formulazioni.

5.3.2 Analisi qualitativa e selezione

Le differenze prestazionali riflettono la conformazione delle mappe di attivazione (Tabella 5.2).

Metodo WSOL	Struttura dell'Attivazione	Rischio Principale Identificato
Linear-CAM	Continua, densa, guidata dai pesi di classe	Lieve dilatazione sul contesto contiguo
DINO Self-Attention	Puntiforme, focalizzata sul nucleo	Sottostima del perimetro di grandi scene
Eigen-CAM	Bimodale, guidata dal contrasto visivo	Attivazione su elementi di foreground errati
Grad-CAM	Sparsa, frammentata sulle patch	Incertezza ai bordi ad alta frequenza

Tabella 5.2: Comportamento qualitativo e rischi strutturali dei metodi WSOL indagati.

Come illustrato nella Figura 5.2, Linear-CAM produce una copertura uniforme e coerente con la sagoma dell'oggetto nei soggetti di scala Macro e Full-Frame (a–c), mentre manifesta dispersioni e salienze spurie sui dettagli Tiny (d–f). Per l'elevata affidabilità complessiva sui target principali, il metodo è stato selezionato per generare il dataset distillato per YOLO.

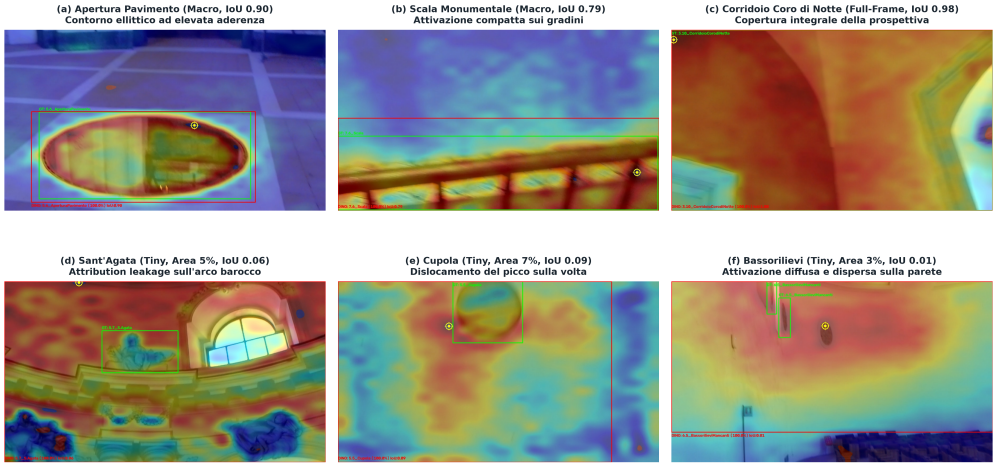

Figura 5.2: Analisi qualitativa di Linear-CAM a confronto con il ground truth: (a–c) successi su scale Macro e Full-Frame con elevata concordanza geometrica (IoU ≥ 0.79); (d–f) fallimenti tipici su elementi Tiny dovuti a dispersione contestuale e dislocamento del picco di salienza (Verde: Ground Truth, Rosso: predizione DINO, Giallo: picco di attivazione).

CAPITOLO 6

Distillazione della Conoscenza in YOLO

6.1 Costruzione del Dataset Pseudo-Etichettato

Per trasferire la capacità di localizzazione dal modello teacher (DINOv3 con Linear-CAM) a un rilevatore real-time (lo studente), è stato impostato un flusso di distillazione basato su pseudo-etichettatura automatica (Figura 6.1).

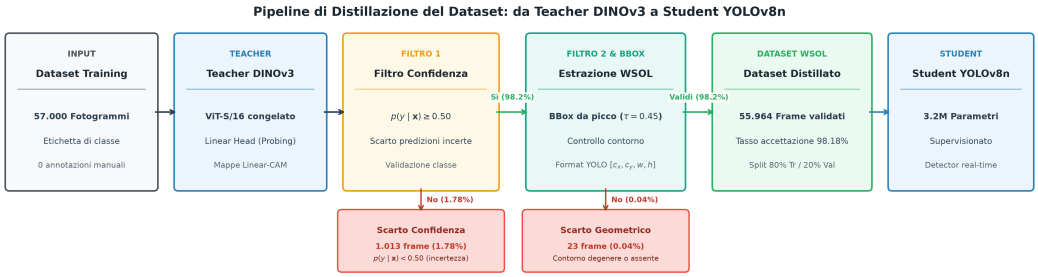

Figura 6.1: Flusso di distillazione del dataset: inferenza del Teacher DINOv3, filtraggio di confidenza, estrazione dei bounding box Linear-CAM, codifica YOLO e addestramento dello Student YOLOv8n.

6.1.1 Criteri di selezione e codifica

Per limitare il rumore nelle etichette stimate, sono stati imposti due filtri di accettazione:

1. **Soglia di confidenza**: vengono tenuti solo i fotogrammi con probabilità a posteriori del classificatore $p(y \mid \mathbf{x}) \geq 0.50$.

2. **Validità geometrica del contorno**: la mappa Linear-CAM binarizzata ($\tau = 0.45$, elemento ellittico 7×7) deve generare almeno un contorno chiuso non degenere che racchiuda il picco di attivazione.

I vertici del rettangolo minimo $[x, y, w, h]$ sono poi normalizzati sulle dimensioni del frame (W, H) secondo il formato YOLO: $c_x = (x + w/2)/W$, $c_y = (y + h/2)/H$, $w_n = w/W$, $h_n = h/H$.

6.1.2 Statistiche della distillazione

Filtrando l'insieme di 57.000 immagini di training con queste regole si ottengono i volumi riportati nella Tabella 6.1.

Il dataset distillato include 55.964 fotogrammi etichettati automaticamente (98.18% del totale), senza richiedere coordinate manuali.

Categoria di Esito	Numero Fotogrammi	Percentuale
Fotogrammi validati e pseudo-etichettati	**55.964**	**98.18%**
Scartati per confidenza insufficiente ($p < 0.50$)	1.013	1.78%
Scartati per contorno degenere o assente	23	0.04%
Totale fotogrammi elaborati	**57.000**	**100.00%**

Tabella 6.1: Statistiche quantitative del processo di distillazione del dataset.

6.2 Addestramento dello Studente (YOLOv8n)

6.2.1 Scelta architetturale

Come modello studente è stato scelto YOLOv8n [10] per due ragioni pratiche:

- **Efficienza computazionale**: con 3.2 M di parametri e 8.7 GFLOPs, supera 120 FPS su GPU standard, prestandosi all'uso su visori egocentrici o dispositivi portatili.
- **Capacità di regolarizzazione**: la taglia ridotta della rete limita l'overfitting sul rumore ad alta frequenza presente nei contorni estratti dalle CAM.

6.2.2 Partizionamento e iperparametri

La suddivisione tra training e validazione ricalca il criterio 80%/20% per classe usato per DINOv3:

- **Train set distillato**: 44.771 fotogrammi;
- **Validation set distillato**: 11.193 fotogrammi.

I dettagli di addestramento sono elencati nella Tabella 6.2.

Iperparametro	Valore	Descrizione Operativa
Risoluzione ingresso (`imgsz`)	640×640 px	Risoluzione di default per YOLOv8
Ottimizzatore	SGD + Momentum	Momentum 0.937, Weight Decay 5×10^{-4}
Learning Rate iniziale (`lr0`)	0.01	Decadimento lineare con warm-up iniziale
Dimensione Batch	16	Con Batch Normalization
Numero massimo di epoche	100	Early stopping con pazienza di 20 epoche
Data Augmentation	Mosaic, Flip, HSV	Mosaic disattivato nelle ultime 10 epoche

Tabella 6.2: Iperparametri di addestramento di YOLOv8n sul dataset distillato.

6.3 Convergenza Interna e Gap di Generalizzazione

Sul validation set interno (misurato rispetto alle pseudo-label del teacher), lo studente apprende a riprodurre i riquadri con alta precisione:

$$\text{Val mAP@50 (Pseudo-Label)} = 96.64\%, \quad \text{Val mAP@50:95} = 86.66\% \tag{6.1}$$

Tuttavia, valutato sul test set ufficiale (5.462 immagini reali verificate contro le annotazioni umane di ground truth), il modello ottiene:

$$\text{Test mAP@50 (Ground Truth)} = 37.39\%, \quad \text{Test mAP@50:95} = 25.84\% \tag{6.2}$$

Questo scarto distingue la fedeltà intra-dominio (96.64%, in cui la rete impara a replicare le decisioni del teacher sullo stesso tipo di riprese) dalla generalizzazione reale sul ground truth (37.39%). Sul risultato pesano il disallineamento tra le sessioni di visita e la forma intrinsecamente approssimata dei contorni generati dalle CAM rispetto ai box umani. Il capitolo successivo inserisce questo risultato nel protocollo comparativo di sample efficiency.

CAPITOLO 7

Baseline Supervisionate e Protocollo di Sample Efficiency

7.1 Obiettivo e Disegno Sperimentale

La domanda di ricerca che guida il confronto è:

> *«A quale frazione di dati annotati manualmente con bounding box equivale un modello addestrato senza alcuna annotazione geometrica supervisionata?»*

Per misurare questo rapporto in modo controllato, è stato impostato il protocollo di *sample efficiency* illustrato nella Figura 7.1. Il modello YOLOv8n distillato (0% di coordinate supervisionate) viene confrontato con rilevatori identici addestrati su frazioni progressive di etichette reali (*ground truth*).

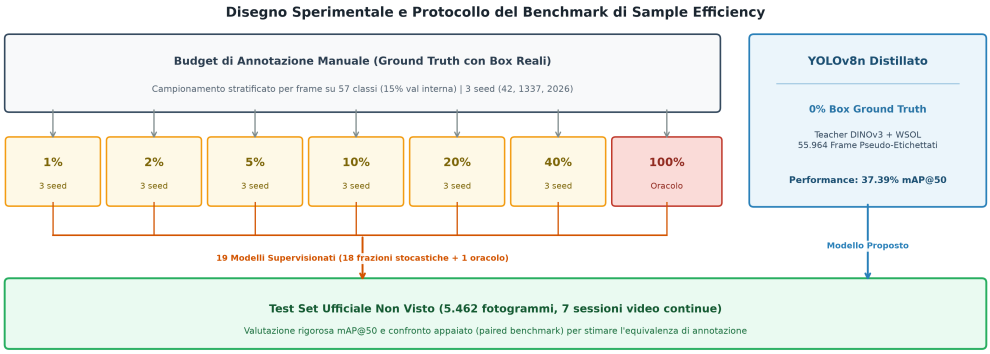

Figura 7.1: Disegno sperimentale del benchmark di Sample Efficiency: partizionamento stratificato del budget di annotazione umana su 7 frazioni (con 3 repliche stocastiche e validazione interna), confrontato con lo studente distillato sul test set ufficiale non visto.

7.1.1 Frazioni di campionamento e controllo della varianza

La curva di apprendimento supervisionata è stata campionata su sette quote:

$$\mathcal{F} = \{1\%,\ 2\%,\ 5\%,\ 10\%,\ 20\%,\ 40\%,\ 100\%\} \tag{7.1}$$

Per le frazioni inferiori al 100% sono stati adottati tre criteri sperimentali:

- **Stratificazione per classe**: la quota $\alpha \in \mathcal{F}$ è calcolata sul numero di immagini di ciascuna delle 57 classi, rispecchiando una campagna di etichettatura bilanciata.
- **Tre seed stocastici**: per limitare la varianza campionaria a bassi volumi di dati, gli addestramenti sotto il 100% sono stati eseguiti su 3 seed casuali (seed $\in \{42, 1337, 2026\}$) con disegno a blocchi appaiati, calcolando media e deviazione standard ($\mu \pm \sigma$).

- **Validazione interna (**15%**)**: ogni partizione riserva il 15% dei fotogrammi all'early stopping e alla scelta del miglior checkpoint, senza toccare il test set esterno.

7.2 Metriche di Valutazione e Condizioni di Fairness

Tutti i modelli sono valutati sul test set ufficiale (5.462 immagini, con 3.673 annotazioni di POI su 7 sessioni continue). Le metriche registrate sono mAP@50 (IoU ≥ 0.50), mAP@50:95 (media integrale su soglie da 0.50 a 0.95 a passo 0.05) e le prestazioni suddivise per tier dimensionale.

Per isolare l'effetto della quantità di dati ed evitare discrepanze esterne, i modelli condividono la medesima impostazione:

1. **Architettura**: YOLOv8n (3.2 M parametri, 8.7 GFLOPs) per ogni configurazione.
2. **Inizializzazione**: pesi pre-addestrati COCO rilasciati da Ultralytics.
3. **Condizioni di addestramento**: risoluzione 640×640, ottimizzatore SGD con momentum (0.937), weight decay 5×10^{-4}, funzione di perdita comune (BCE + CIoU + DFL), massimo 100 epoche e stessa data augmentation (Mosaic, HSV, flip).
4. **Test set intatto**: nessun fotogramma di test è stato utilizzato per calibrazione o regolazione degli iperparametri.

CAPITOLO 8

Risultati Sperimentali e Analisi Critica

8.1 Risultati Globali: Punto di Pareggio e Ritenzione di Capacità

Il confronto mette a contrasto due scenari: le baseline supervisionate apprendono da coordinate cartesiane tracciate manualmente da operatori; il modello distillato apprende invece senza coordinate manuali, estraendo i riquadri dalle mappe Linear-CAM del classificatore DINOv3.

La Tabella 8.1 riporta i risultati sul test set ufficiale (5.462 immagini, 3.673 annotazioni di POI).

Configurazione	Quota GT	Seed	mAP@50 (%)	mAP@50:95 (%)
Supervisionato	1%	3 seed	$34.33 \pm 1.48\%$	$22.77 \pm 1.12\%$
Supervisionato	2%	3 seed	$40.50 \pm 1.25\%$	$27.43 \pm 0.98\%$
Supervisionato	5%	3 seed	$49.20 \pm 0.85\%$	$34.12 \pm 0.65\%$
Supervisionato	10%	3 seed	$53.80 \pm 0.72\%$	$37.89 \pm 0.54\%$
Supervisionato	20%	3 seed	$57.10 \pm 0.61\%$	$40.65 \pm 0.48\%$
Supervisionato	40%	3 seed	$59.40 \pm 0.45\%$	$42.80 \pm 0.35\%$
Oracolo 100%	**100%**	1 seed	**60.51%**	**43.90%**
YOLOv8n Distillato	**0% GT (WSOL)**	—	**37.39%**	**25.84%**

Tabella 8.1: Confronto prestazionale tra baseline supervisionate (7 frazioni GT con 3 seed stocastici) e YOLOv8n distillato (0% GT) sul Test Set ufficiale.

I dati evidenziano due indicatori principali:

1. **Punto di pareggio (Breakeven Point)**: con un mAP@50 del 37.39%, lo studente distillato si colloca tra la baseline all'1% (34.33%) e quella al 2% (40.50%). Tramite interpolazione lineare:

$$\alpha_{\text{breakeven}} = 1.0 + \frac{37.39 - 34.33}{40.50 - 34.33} \cdot (2.0 - 1.0) \approx 1.49\% \text{ di dati Ground Truth} \quad (8.1)$$

   L'addestramento su pseudo-label DINOv3 equivale sul piano empirico a disporre dell'1.49% di etichette tracciate a mano sull'intero corpus.

2. **Ritenzione di capacità (Capacity Retention)**: rispetto all'oracolo supervisionato al 100% (60.51% mAP@50), lo studente distillato recupera:

$$\text{Capacity Retention} = \frac{37.39\%}{60.51\%} \approx 61.79\% \quad (8.2)$$

   trattenendo oltre i tre quinti della prestazione massima a costo di annotazione geometrica nullo.

8.2 Analisi Disaggregata per Scala (Tier Dimensionale)

La Tabella 8.2 e la Figura 8.1 mostrano l'andamento del modello sui diversi tier dimensionali.

Tier	Classi	Base 1%	Distillato	Oracolo	Pareggio	Ritenzione
Full-Frame (≥ 0.80)	23	$23.50 \pm 2.15\%$	**45.67%**	54.28%	$\approx 6.0\%$	**84.14%**
Macro ($0.30 - 0.79$)	26	$32.42 \pm 1.73\%$	**37.71%**	59.29%	$\approx 1.4\%$	**63.60%**
Small ($0.11 - 0.30$)	3	$62.92 \pm 4.44\%$	**9.01%**	85.49%	$< 1\%$	**10.54%**
— *Tiny* (≤ 0.10)	4	$65.81 \pm 3.12\%$	**0.00%**	88.15%	0%	**0.00%**

Tabella 8.2: Prestazioni comparative di mAP@50 (%) e ritenzione disaggregate per tier.

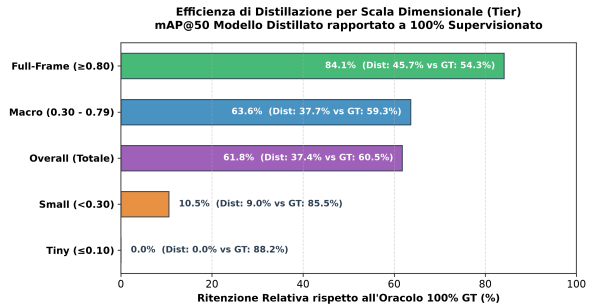

Figura 8.1: Ritenzione relativa di mAP@50 dello studente distillato (0% GT) rispetto all'oracolo 100% disaggregata per tier dimensionale.

Il riscontro più significativo sul piano applicativo riguarda il Tier Macro (26 classi, con area media compresa tra il 30% e il 79% del fotogramma), che raccoglie altari, portali e affreschi. In questa fascia, dove la localizzazione richiede l'effettiva stima dei confini rispetto allo sfondo, la pipeline mantiene il 63.60% delle prestazioni dell'oracolo e supera la baseline supervisionata all'1% (37.71% contro 32.42%). Nei soggetti di dimensioni ridotte (Tier Small e Tiny) le prestazioni invece scendono bruscamente, azzerandosi sulle 4 classi del Tier Tiny.

8.3 Analisi del Tier Tiny: Bias Contestuale e Attribution Leakage

Il mancato rilevamento sul Tier Tiny (0.00% mAP@50 sulle 4 classi *Sant'Agata*, *Cupola*, *Santa Scolastica* e *Bassorilievi Mancanti*) non dipende dalla risoluzione a griglia (24×24 patch), ma da un problema di selezione delle feature discriminative (Figura 8.2).

Osservando le attivazioni locali, si nota che DINOv3 separa con chiarezza la silhouette dell'oggetto dalle pareti. Il picco massimo ($\arg\max \mathcal{H}$), tuttavia, scivola sulle strutture architettoniche limitrofe o sulle superfici contigue (l'arco per Sant'Agata, la volta per la Cupola, la cornice per Santa Scolastica, la parete muraria per i Bassorilievi Mancanti). Questo comportamento discende dal bias contestuale insito nella supervisione d'immagine:

1. La funzione di costo $\mathcal{L}_{\text{CE}}$ premia qualunque indizio visivo utile a distinguere la classe dalle altre 56 presenti nell'edificio.

2. Un manufatto di piccole dimensioni co-occorre in modo costante con lo sfondo architettonico fisso (l'arco o la volta), che offre una superficie visiva molto più estesa e ricca di pattern.

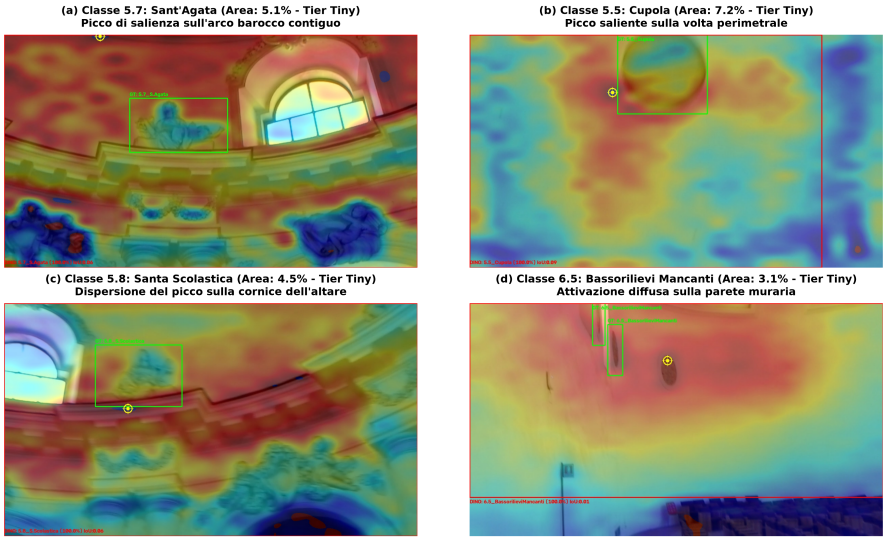

Figura 8.2: Disallineamento discriminativo sui quattro soggetti del Tier Tiny: (a) Sant'Agata (area 5.1%), (b) Cupola (area 7.2%), (c) Santa Scolastica (area 4.5%) e (d) Bassorilievi Mancanti (area 3.1%). In tutti i casi le mappe di salienza isolano porzioni del reperto, ma il picco globale di attivazione (mirino giallo) si sposta sulla struttura architettonica contigua o sullo sfondo murario, generando uno pseudo-box errato (rosso) rispetto al Ground Truth (verde).

3. Il modello apprende una scorciatoia statistica (*shortcut learning*): riconosce la scena con precisione (94.38%), ma posiziona il picco di calore sull'elemento di contesto anziché sull'opera, producendo un riquadro con IoU < 0.10 rispetto al ground truth.

8.4 Baseline Box a Tutta Immagine e Disaccoppiamento

Nel Tier Full-Frame (copertura media del 93%), un riquadro fisso esteso all'intero fotogramma $[0.5, 0.5, 1.0, 1.0]$ produce per pura geometria un IoU $\approx 0.93 \gg 0.50$. In questa fascia, localizzare debolmente l'oggetto coincide nei fatti con la corretta classificazione della scena. Nel Tier Macro, invece, il riquadro banale fallisce (IoU $\in [0.30, 0.79]$). Il raggiungimento del 37.71% di mAP@50 e del 63.60% di ritenzione conferma che la rete isola i contorni dell'oggetto dallo sfondo circostante.

8.5 Gap di Generalizzazione dello Studente

Il divario tra la validazione dello studente YOLOv8n (96.64% mAP@50 su pseudo-label) e la valutazione sul test set (37.39% su ground truth) riflette due fenomeni concorrenti: l'*attribution leakage* sulle classi più piccole e il disallineamento cinematico tra le inquadrature stabili del training e le 7 sessioni video continue del test set.

CAPITOLO 9

Limiti della Metodologia

9.1 Assunzione di Singola Istanza per Immagine

L'algoritmo di estrazione dei riquadri assume che in ogni fotogramma compaia una sola istanza del soggetto: l'ancoraggio al picco globale ($\arg\max \mathcal{H}$) seleziona unicamente il contorno con intensità massima, ignorando eventuali occorrenze secondarie. Quando compaiono più elementi omologhi nella stessa inquadratura (come i lavamani gemelli `6.6` e `6.7`, o le poltrone `6.9`), il sistema identifica solo l'istanza più evidente oppure unisce gli oggetti in un unico grande rettangolo se l'apertura morfologica non li disaccoppia.

9.2 Bias Contestuale e Disallineamento Discriminativo

L'addestramento con etichette a livello di immagine sviluppa, negli ambienti chiusi del monastero, un evidente bias di contesto. La perdita di Cross-Entropy valorizza elementi murari fissi di ampia superficie (volte, archi e pareti decorate), spingendo il massimo di calore al di fuori dell'opera da rilevare (*attribution leakage*): $(x^*, y^*) = \arg\max \mathcal{H}(x, y) \notin \mathrm{BBox}_{\mathrm{GT}}$. Questo fenomeno azzera la localizzazione sui soggetti di scala ridotta (Tier Tiny), nonostante il modello riconosca la classe dell'immagine con precisione.

9.3 Rigidità della Soglia Costante

La soglia proporzionale fissa ($\tau = 0.45 \cdot \max$) costituisce un compromesso rigido: efficace nei contesti a contrasto netto, tende a escludere le parti periferiche dei soggetti a sfumatura continua, sottostimando la reale ampiezza del perimetro rispetto alle annotazioni umane. L'assenza di un criterio dinamico basato sull'entropia locale delle attivazioni limita la precisione dell'estrazione.

9.4 Approssimazione Rettangolare di Maschere Irregolari

Le mappe di salienza di DINOv3 producono sagome continue e irregolari. L'obbligo di circoscrivere la regione con rettangoli allineati agli assi (AABB), imposto dal formato di YOLO, include porzioni cospicue di sfondo nei soggetti orientati in diagonale o asimmetrici (scalinate, archi prospettici). Questa approssimazione penalizza le valutazioni a soglie IoU più severe (mAP@75 e mAP@50:95, pari al 25.84%).

9.5 Domain Shift Dinamico tra Training e Test

Il dataset presenta una differenza cinematica tra le partizioni: il set di addestramento è organizzato per cartelle di classe con inquadrature stabili, mentre il test set deriva da 7 sessioni video continue a passo d'uomo (`Test1`–`Test7`) soggette a rotazioni rapide, occlusioni parziali e sfocature da movimento (*motion blur*). Il teacher DINOv3 lavora su immagini

statiche isolate, generando pseudo-label che risentono delle fluttuazioni dinamiche tipiche delle riprese reali.

CAPITOLO 10

Conclusioni e Sviluppi Futuri

10.1 Risposta alla Domanda di Ricerca

In questo lavoro è stato misurato il valore pratico delle annotazioni manuali sostituite da una pipeline di distillazione debolmente supervisionata guidata da DINOv3.

I test condotti sul dataset UNICT-VEDI POI indicano tre risultati principali:

1. **Punto di pareggio (**1.43% **di etichette manuali)**: lo studente YOLOv8n addestrato sulle mappe Linear-CAM ottiene il 37.39% di mAP@50, superando la baseline supervisionata all'1% (34.33%) e raggiungendo un punto di pareggio stimato all'1.43% di annotazioni umane.
2. **Ritenzione di capacità (**61.79% **dell'oracolo)**: rispetto al limite superiore dell'oracolo supervisionato al 100% (60.51%), il modello distillato recupera oltre tre quinti delle prestazioni complessive. Nel Tier Macro (26 classi complesse con area compresa tra il 30% e il 79%, dove la localizzazione non è banale), la quota trattenuta raggiunge il 63.60%.
3. **Comportamento sulle classi Tiny**: il mancato rilevamento sui target di taglia ridotta (0.00% mAP@50) non è causato dalla risoluzione della griglia dei token: DINOv3 isola la sagoma dell'oggetto, ma la loss di classificazione globale concentra il picco di attivazione sullo sfondo murario (*attribution leakage*).

10.2 Sviluppi Futuri

I risultati suggeriscono quattro direzioni di approfondimento metodologico:

1. **Rilevamento di istanze multiple**: integrare meccanismi di cross-attention o prompt semantici sui token di DINOv3 per separare riquadri distinti nelle inquadrature che contengono copie multiple dello stesso elemento.
2. **Classificazione gerarchica multi-etichetta**: sfruttare l'alta accuratezza del classificatore nell'identificare il macro-ambiente (92.87%) con un modello a due stadi (ambiente → POI), impiegando una perdita BCE multi-label con attivazioni Sigmoid indipendenti per slegare l'attivazione della stanza da quella dell'oggetto.
3. **Regolarizzazione contrastiva sui token**: applicare una perdita contrastiva a livello di patch per penalizzare l'attivazione spuria su strutture architettoniche fisse (archi, volte), concentrando l'attenzione sulle specificità dell'opera.
4. **Valutazione disaccoppiata**: affiancare al mAP standard la metrica Correct Localization (CorLoc) [3] e il mAP *class-agnostic*, per separare la precisione geometrica del riquadro dalla correttezza dell'etichetta semantica.

Bibliografia

[1] O. Siméoni, H. V. Vo, M. Seitzer, *et al.*, "Dinov3," *arXiv preprint arXiv:2508.10104*, 2025.

[2] F. Ragusa, A. Furnari, S. Battiato, G. Signorello, and G. M. Farinella, "Egocentric point of interest recognition in cultural sites," in *Proceedings of the 14th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications (VISIGRAPP/VISAPP)*, vol. 5, pp. 248–259, 2019.

[3] J. Choe, S. J. Oh, S. Lee, S. Chun, Z. Akata, and Y. Uh, "Evaluating weakly supervised object localization methods right," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 3133–3142, 2020.

[4] X. Zhang, Y. Wei, J. Feng, Y. Yang, and T. S. Huang, "Adversarial complementary learning for weakly supervised object localization," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1325–1334, 2018.

[5] C. Bilgi and R. G. Cinbis, "Weakly supervised object localization with inter-image semantic similarities," *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, vol. 44, no. 11, pp. 8380–8394, 2021.

[6] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin, "Emerging properties in self-supervised vision transformers," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 9650–9660, 2021.

[7] M. Oquab, T. Darcet, T. Moutakanni, H. V. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, *et al.*, "Dinov2: Learning robust visual features without supervision," *Transactions on Machine Learning Research (TMLR)*, 2023.

[8] M. B. Muhammad and M. Yeasin, "Eigen-cam: Class activation map using principal components," in *International Joint Conference on Neural Networks (IJCNN)*, pp. 1–7, 2020.

[9] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *IEEE International Conference on Computer Vision (ICCV)*, pp. 618–626, 2017.

[10] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics yolov8." https://github.com/ultralytics/ultralytics, 2023.

[11] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations (ICLR)*, 2021.

[12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[13] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, “Learning deep features for discriminative localization,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2921–2929, 2016.

CAPITOLO A

Iperparametri Completi e Protocollo Sperimentale

Questa appendice raccoglie i parametri di configurazione e di addestramento usati per il classificatore DINOv3, per la pipeline deterministica WSOL, per il modello YOLOv8n distillato e per il protocollo di sample efficiency.

A.1 Classificatore DINOv3 (Linear Probing)

A.2 Pipeline di Estrazione Bounding Box (WSOL)

A.3 Addestramento del Modello Studente (YOLOv8n Distillato)

A.4 Protocollo Sperimentale di Sample Efficiency

Categoria	Iperparametro	Valore	Note e Rationale
Backbone	Modello	`dinov3-vits16`	ViT-S/16 preaddestrato da Meta su LVD-1689M
	Dimensione latente (D)	384	Dimensione del token di embedding
	Numero di strati (L)	12	Blocchi sequenziali di Transformer Encoder
	Teste attenzione (h)	6	Dimensionalità per testa $d_k = 64$
	Dimensione patch (P)	16×16 px	Risoluzione nativa del patch embedding
	Stato pesi backbone	**Frozen**	Pesi congelati; nessun gradiente retropropagato
Testa Classe	Architettura	Dropout + Linear	Proiezione lineare diretta dal token CLS
	Dropout rate	0.3	Regolarizzazione per contrastare il co-adattamento
	Numero classi output	57	Corrispondenti ai 57 POI del dataset VEDI
Dati & Runtime	Risoluzione ingresso	384×384 px	Griglia discreta di patch pari a 24×24 (576 token)
	Normalizzazione	Canali ImageNet	$\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$
	Batch size	16	Campioni per iterazione di ottimizzazione
	Data Augmentation	Flip + Color Jitter	Horizontal Flip ($p = 0.5$); Jitter contrasto/luce ($p = 0.5$)
Ottimizzazione	Ottimizzatore	AdamW	$\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$
	Learning Rate (η_0)	1×10^{-4}	Ottimizzato su testa lineare
	Weight Decay	1×10^{-4}	Penalizzazione L_2 per regolarizzazione pesi
	Scheduler	Cosine Annealing	Decadimento cosinusoidale con riscaldamento
	Epoche totali	20	Miglior checkpoint all'epoca 13 (Val Acc 98.31%)

Tabella A.1: Specifiche dettagliate del classificatore DINOv3 in regime di Linear Probing.

Componente	Parametro	Valore	Funzione nel Sistema
Attribuzione	Metodo Primario	`Linear-CAM`	Proiezione: $\text{ReLU}(\mathbf{w}_c^\top \mathbf{z}_{i,j})$
	Metodi Confronto	`dino_attn`, `eigen`, `grad`	Utilizzati per il benchmark comparativo (Cap. 5)
Preprocessing	Risoluzione estrazione	24×24 celle	Risoluzione nativa della griglia di patch ViT
	Normalizzazione	Min-Max $[0.0, 1.0]$	$\hat{M} = (M - \min M)/(\max M - \min M + \epsilon)$
	Interpolazione	Bicubica	Proiezione alla risoluzione nativa (W, H)
	Spazio Colore Output	Scala di grigi 8-bit	Mappatura nell'intervallo discreto $[0, 255]$
Binarizzazione	Soglia `Linear-CAM`	$\tau = 0.45 \cdot \max$	Taglio relativo proporzionale al picco
	Soglia `DINO Attn`	Percentile 50°	Taglio dinamico sulla mediana di densità
	Area Minima	5% dell'immagine	Espansione isotropa contro collasso sub-risoluzione
Morfologia	Elemento Strutturante	Ellittico 7×7 px	Operazione di apertura: erosione e dilatazione
	Criterio Contorno	Picco Assoluto	Selezione del poligono su $\arg\max \mathcal{H}(x, y)$
	Formato Box	AABB Normalizzato	Rettangolo asse-allineato $[c_x, c_y, w, h] \in [0, 1]^4$

Tabella A.2: Parametri operativi della pipeline deterministica WSOL.

Ambito	Iperparametro	Valore	Descrizione Operativa
Modello	Architettura	`YOLOv8n`	Variante compatta (*nano*), ≈ 3.2 M parametri
	Inizializzazione	Pretrained COCO	Pesi di partenza ufficiali Ultralytics (`yolov8n.pt`)
Dati & Training	Risoluzione ingresso	640×640 px	Risoluzione standard YOLO per rilevamento fine
	Batch size	16	Esempi per iterazione
	Numero classi (nc)	57	Mapping coerente con la tassonomia naturale VEDI
	Durata training	100 epoche	Epoche massime previste
	Early Stopping	20 epoche	Arresto anticipato in caso di stallo su mAP
Ottimizzazione	Ottimizzatore	SGD	Discesa del gradiente stocastica con momentum
	Momentum	0.937	Coefficiente di inerzia dell'aggiornamento
	Weight Decay	5×10^{-4}	Regolarizzazione L_2 sui pesi
	Learning Rate iniziale	0.01	Tasso iniziale di apprendimento (`lr0`)
	Warmup	3.0 epoche	Transizione iniziale a gradiente controllato
Augmentation	Mosaic	1.0 (off a -10 ep.)	Composizione di 4 fotogrammi
	Horizontal Flip	0.5	Probabilità di specchiatura orizzontale
	Variazione Scala	$\pm 50\%$	Alterazione casuale delle dimensioni
	Perturbazione HSV	$h = 0.015, s = 0.7, v = 0.4$	Fluttuazioni cromatiche casuali

Tabella A.3: Iperparametri completi di addestramento per YOLOv8n distillato.

Parametro	Valore	Rationale Sperimentale
Frazioni di Supervisione ($\mathcal{F}$)	$\{1\%, 2\%, 5\%, 10\%, 20\%, 40\%, 100\%\}$	Scala logaritmica/geometrica asintotica
Criterio di Campionamento	Stratificato per fotogrammi	Rispecchia il costo reale del tempo umano
Semi Casuali ($< 100\%$)	$\{42, 1337, 2026\}$ (3 seed)	Controllo rigoroso della varianza stocastica
Disegno Sperimentale	A blocchi appaiati (*Paired*)	Medesimi 3 seed per tutte le frazioni
Partizione Validazione	15% del subset estratto	Riservato unicamente a early stopping
Pazienza Early Stopping	15 epoche	Gestione della rumorosità su micro-dataset
Valutazione Test Set	Miglior checkpoint	Valutazione su 5.462 immagini indipendenti

Tabella A.4: Parametri di controllo del benchmark comparativo di Sample Efficiency.

CAPITOLO B

Tassonomia Completa delle Classi e Aree Medie

Questa appendice elenca le 57 classi di punti di interesse del dataset UNICT-VEDI POI, registrate presso il Monastero dei Benedettini di Catania.

Per ciascuna classe sono indicati:

- **ID**: indice numerico secondo l'ordinamento naturale del dataset ($[0, 56]$).
- **Nome POI / Cartella**: denominazione della classe con prefisso dell'ambiente ($1 \ldots 9$).
- **Tier Dimensionale**: fascia di scala assegnata (*Tiny*, *Small*, *Macro*, *Full-Frame*).
- **Area Media Relativa ($\bar{A}_c$)**: frazione media di superficie ($w \times h$) del riquadro di ground truth rispetto all'immagine.
- **Copertura %**: area media espressa in percentuale dell'inquadratura.

B.1 Prospetto delle 57 Classi POI

ID	Nome POI / Cartella	Tier	Area Media ($\bar{A}_c$)	Copertura
0	1.1_Ingresso	**Full-Frame**	0.998	99.8%
1	2.1_RampaS.Nicola	**Full-Frame**	0.998	99.8%
2	2.2_RampaS.Benedetto	**Full-Frame**	0.998	99.8%
3	3.1_SimboloTreBiglie	**Full-Frame**	0.891	89.1%
4	3.2_ChiostroLevante	**Macro**	0.739	73.9%
5	3.3_Plastico	**Full-Frame**	0.890	89.0%
6	3.4_Affresco	**Macro**	0.629	62.9%
7	3.5_FinestraChiostroLevante	**Macro**	0.688	68.8%
8	3.6_PortaCorodiNotte	**Full-Frame**	0.998	99.8%
9	3.7_TracciaPortone	**Macro**	0.486	48.6%
10	3.8_StanzaAbate	**Macro**	0.612	61.2%
11	3.9_CorridoiodiLevante	**Full-Frame**	0.998	99.8%
12	3.10_CorridoioCorodiNotte	**Full-Frame**	0.998	99.8%
13	3.11_CorridoioOrologio	**Full-Frame**	0.998	99.8%
14	4.1_Quadro	**Macro**	0.396	39.6%
15	4.2_PavimentoOrig.Altare	**Macro**	0.632	63.2%
16	4.3_BalconeChiesa	**Full-Frame**	0.998	99.8%
17	5.1_PortaAulaS.Mazzarino	**Macro**	0.648	64.8%
18	5.2_PortaIngressoMuseoFabbrica	**Macro**	0.459	45.9%
19	5.3_PortaAntirefettorio	**Macro**	0.757	75.7%
20	5.4_PortaIngressoRef.Piccolo	**Macro**	0.661	66.1%
21	5.5_Cupola	**Tiny**	0.072	7.2%
22	5.6_AperturaPavimento	**Macro**	0.571	57.1%

Continua nella pagina seguente

ID	Nome POI / Cartella	Tier	Area Media ($\bar{A}_c$)	Copertura
23	5.7_S.Agata	**Tiny**	0.051	5.1%
24	5.8_S.Scolastica	**Tiny**	0.045	4.5%
25	5.9_ArcoconFirma	**Macro**	0.751	75.1%
26	5.10_BustoVaccarini	**Macro**	0.536	53.6%
27	6.1_QuadroSantoMazzarino	**Small**	0.219	21.9%
28	6.2_Affresco	**Macro**	0.576	57.6%
29	6.3_PavimentoOriginale	**Macro**	0.632	63.2%
30	6.4_PavimentoRestaurato	**Full-Frame**	0.964	96.4%
31	6.5_BassorilieviMancanti	**Tiny**	0.031	3.1%
32	6.6_LavamaniSx	**Small**	0.272	27.2%
33	6.7_LavamaniDx	**Macro**	0.315	31.5%
34	6.8_TavoloRelatori	**Macro**	0.736	73.6%
35	6.9_Poltrone	**Full-Frame**	0.827	82.7%
36	7.1_Edicola	**Full-Frame**	0.895	89.5%
37	7.2_PavimentoA	**Full-Frame**	0.925	92.5%
38	7.3_PavimentoB	**Full-Frame**	0.813	81.3%
39	7.4_Passavivande	**Full-Frame**	0.897	89.7%
40	7.5_AperturaPavimento	**Macro**	0.701	70.1%
41	7.6_Scala	**Macro**	0.746	74.6%
42	7.7_SalaMetereologica	**Full-Frame**	0.998	99.8%
43	8.1_Doccione	**Macro**	0.484	48.4%
44	8.2_VanoRaccoltaCenere	**Macro**	0.591	59.1%
45	8.3_SalaRossa	**Full-Frame**	0.998	99.8%
46	8.4_ScalaCucina	**Macro**	0.536	53.6%
47	8.5_CucinaProvv	**Full-Frame**	0.940	94.0%
48	8.6_Ghiacciaia	**Full-Frame**	0.855	85.5%
49	8.7_Latrina	**Macro**	0.548	54.8%
50	8.8_OssaeScarti	**Macro**	0.647	64.7%
51	8.9_Pozzo	**Full-Frame**	0.817	81.7%
52	8.10_Cisterna	**Macro**	0.786	78.6%
53	8.11_BustoPietroTacchini	**Small**	0.297	29.7%
54	9.1_NicchiaePavimento	**Full-Frame**	0.876	87.6%
55	9.2_TraccePalestra	**Macro**	0.658	65.8%
56	9.3_PergolatoNovizi	**Full-Frame**	0.841	84.1%

CAPITOLO C

Ambiente di Esecuzione, Note Tecniche e Riproducibilità

Questa appendice descrive l'ambiente software, l'hardware impiegato e le impostazioni adottate per assicurare la riproducibilità degli esperimenti.

C.1 Stack Software e Librerie di Riferimento

Il codice è sviluppato in Python 3.12 all'interno di un ambiente virtuale isolato. I principali framework e librerie scientifiche utilizzati sono:

Libreria / Framework	Versione	Funzione Primaria nella Pipeline
PyTorch	`2.1+` (CUDA 12.x)	Computazione GPU, autograd e training DINO
HF Transformers	`5.x`	Modello preaddestrato `dinov3-vits16-pretrain`
Ultralytics	`8.x`	Addestramento e validazione modelli YOLOv8
OpenCV (`cv2`)	`4.x`	Sovracampionamento bicubico, binarizzazione, morfologia
Pillow (`PIL`)	`10.x`	Decodifica ed elaborazione delle immagini RGB
NumPy & SciPy	`1.26+` / `1.12+`	Manipolazioni tensoriali, percentili e SVD
Torchmetrics	`1.x`	Metriche di classificazione (Top-1, Top-5, Macro F1)
Pandas & Matplotlib	`2.x` / `3.8+`	Aggregazione statistica e rendering grafici

Tabella C.1: Ecosistema software e framework scientifici impiegati.

C.2 Risorse Hardware e Accelerazione di Calcolo

Gli esperimenti sono stati condotti su una workstation locale:

- **Unità di Elaborazione Grafica (GPU)**: NVIDIA GeForce RTX 2060 con 6 GB di VRAM (GDDR6).
- **Accelerazione Numerica**: Driver NVIDIA compatibili con CUDA 12 e librerie cuDNN per l'esecuzione dei blocchi convoluzionali e dei moduli di attenzione.
- **Precisione Mista (AMP)**: Negli addestramenti di YOLOv8n è stata attivata l'*Automatic Mixed Precision* (FP16), riducendo l'occupazione di memoria video e accelerando le epoche senza instabilità numeriche nel calcolo delle perdite.

C.3 Protocollo di Riproducibilità e Controllo del Determinismo

Per rendere replicabili le prove sperimentali:

1. **Semi pseudocasuali fissati**: le componenti stocastiche sono state inizializzate con semi prestabiliti:
   - Addestramento del classificatore DINOv3 e della YOLO distillata: seed = 42.
   - Benchmark di Sample Efficiency: esecuzione sistematica sui tre semi seed $\in \{42, 1337, 2026\}$, calcolando media e deviazione standard ($\mu \pm \sigma$).
2. **Determinismo delle primitive CUDA**: impostazione di `cudnn.deterministic = True` in PyTorch per limitare la non-determinatezza degli algoritmi di convoluzione.
3. **Partizionamento dei dati**: il criterio 80/20 per classe (campione a validazione se $i \pmod 5 == 0$) è stato applicato in modo identico sia al training del classificatore DINOv3 sia alla distillazione di YOLOv8n, garantendo il completo allineamento tra i rispettivi insiemi di validazione.

C.4 Condizioni di Licenza e Conformità dei Dati

- **UNICT-VEDI POI Dataset**: rilasciato dall'Image Processing Laboratory (IPLab) dell'Università di Catania per finalità di ricerca e sperimentazione scientifica.
- **Pesi DINOv3**: rilasciati da Meta AI Research sotto licenza di ricerca.
- **Ultralytics YOLO**: concesso sotto licenza AGPL-3.0.